PRE-ENTREGA 6 · POWER QUERY + M

Pipeline ETL de TechStore

De datos crudos a un modelo confiable para Power BI

PROYECTO	ENTREGA
RetailPro / TechStore	Checkpoint: Pipeline ETL con Power Query y lenguaje M
Alumno	Santiago Berardini
Fuente	Pipeline_ETL_Dataset.xlsx
Archivo Power BI	Pipeline_ETL_Berardini_Santiago.pbix

Objetivo

Preparar las tablas de clientes, productos, ventas y categorías mediante un proceso de extracción, transformación y carga (ETL). El resultado conserva los registros de negocio válidos, resuelve problemas de calidad y enriquece la tabla de ventas con los atributos de producto para el análisis de los módulos posteriores.

Resultado comprobado

CONSULTA	ORIGEN	FINAL	VALIDACIÓN
Dim_Clientes	12	11	ID único; nulos descriptivos resueltos
Dim_Productos	13	12	ID único; precio y categoría completados
Fact_Ventas	50	50	Merge por id_producto; 11 columnas
Dim_Categorias	4	4	Catálogo de referencia sin cambios

Nota de alcance: los conteos y la vista final se documentan con capturas reales de Power BI Desktop. El archivo .pbix se entrega como material complementario junto a este PDF.

1. Conexión, perfilado y limpieza

La fuente corresponde al libro Excel del curso, no a la base SQL utilizada en los módulos anteriores. Se trabajó en el Editor de Power Query y se cargaron cuatro consultas con la nomenclatura profesional Dim_ / Fact_.

Calidad de datos: decisiones aplicadas

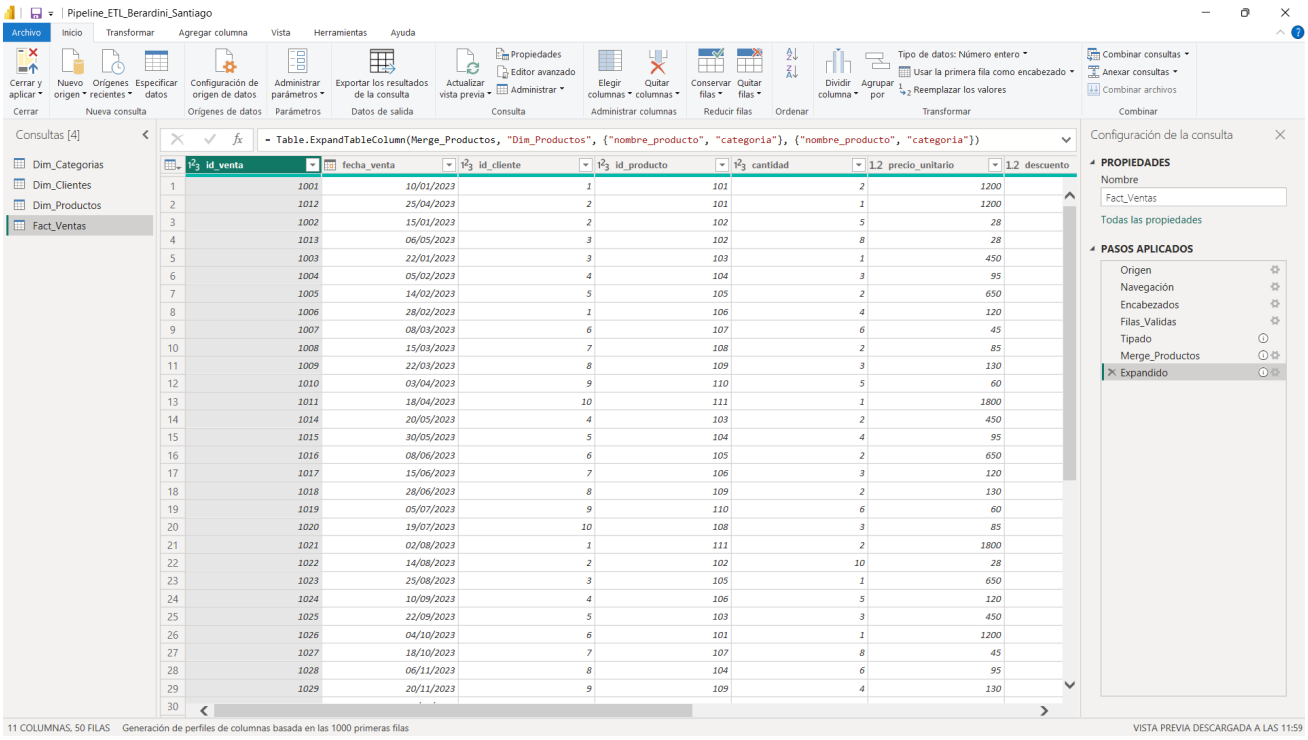
CONSULTA	PROBLEMA	TRANSFORMACIÓN Y CRITERIO
Dim_Clientes	1 ID duplicado	Quitar duplicados por id_cliente para mantener una clave primaria única.
Dim_Clientes	Email nulo, cliente 9	Sustituir por “Sin dato”. Conservar el cliente evita perder la correspondencia con ventas.
Dim_Clientes	Ciudad nula, cliente 11	Sustituir por “Sin dato”. Es un atributo descriptivo, no una clave.
Dim_Productos	ID 103 repetido	Quitar duplicados por id_producto para evitar duplicación de productos al combinar.
Dim_Productos	Precio nulo, producto 109	Imputar 130, valor observado en sus ventas. Requiere validación comercial si fuera una fuente de producción.
Dim_Productos	Categoría nula, producto 111	Asignar “Computación”, coherente con su subcategoría Laptops y productos comparables.
Todas	Filas sin identificador	Filtrar registros con ID nulo antes de tipar y reemplazar valores; evita que filas vacías se conviertan en registros ficticios.

Tipos de datos

TABLA	ASIGNACIÓN
Dim_Clientes	id_cliente: entero; fecha_registro: fecha; nombre_cliente, email, ciudad, pais y segmento: texto.
Dim_Productos	id_producto, stock y activo: entero; precio y costo: decimal; nombre_producto, categoria y subcategoria: texto.
Fact_Ventas	id_venta, id_cliente, id_producto y cantidad: entero; fecha_venta: fecha; precio_unitario, descuento y total_venta: decimal; canal: texto.
Dim_Categorias	id_categoria: entero; nombre_categoria y descripcion: texto.

2. Evidencias de Power Query

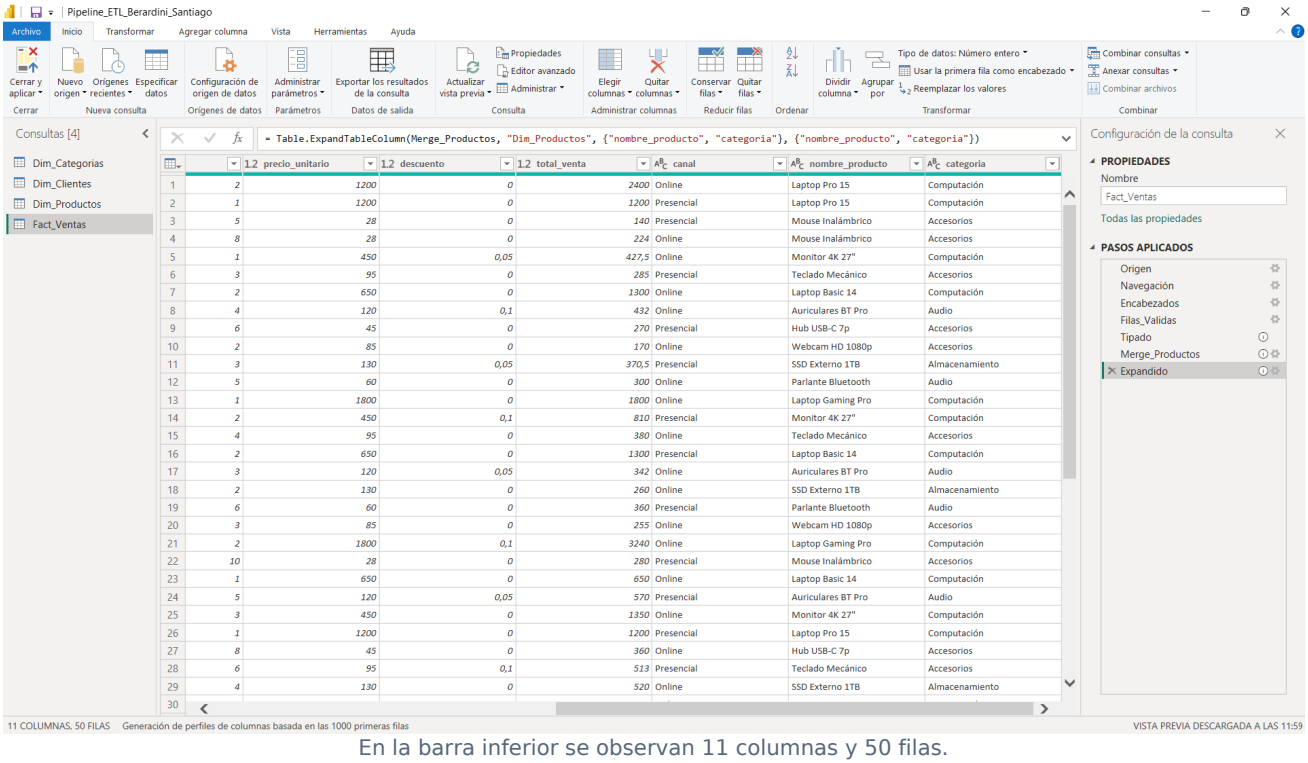
Captura 1. Panel de consultas y pasos aplicados de Fact_Ventas. Se distinguen las cuatro consultas, el filtro Filas_Validas, la combinación Merge_Productos y la expansión final.



Fuente: captura real del Editor de Power Query, posterior a la corrección de filas vacías.

Captura 2. Verificación del resultado del Merge

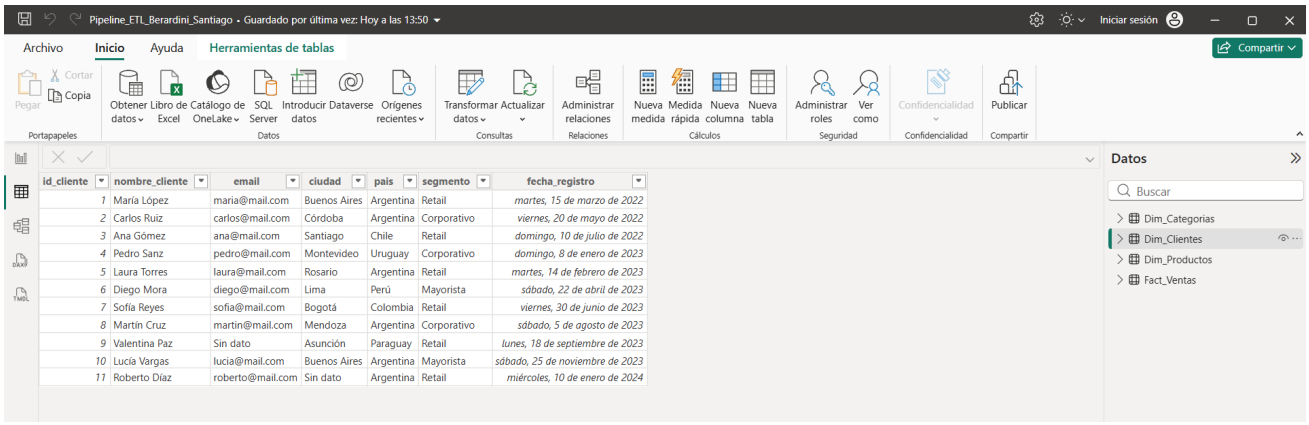
La consulta Fact_Ventas conserva las 50 operaciones y muestra las columnas nombre_producto y categoria incorporadas por la combinación con Dim_Productos.



En la barra inferior se observan 11 columnas y 50 filas.

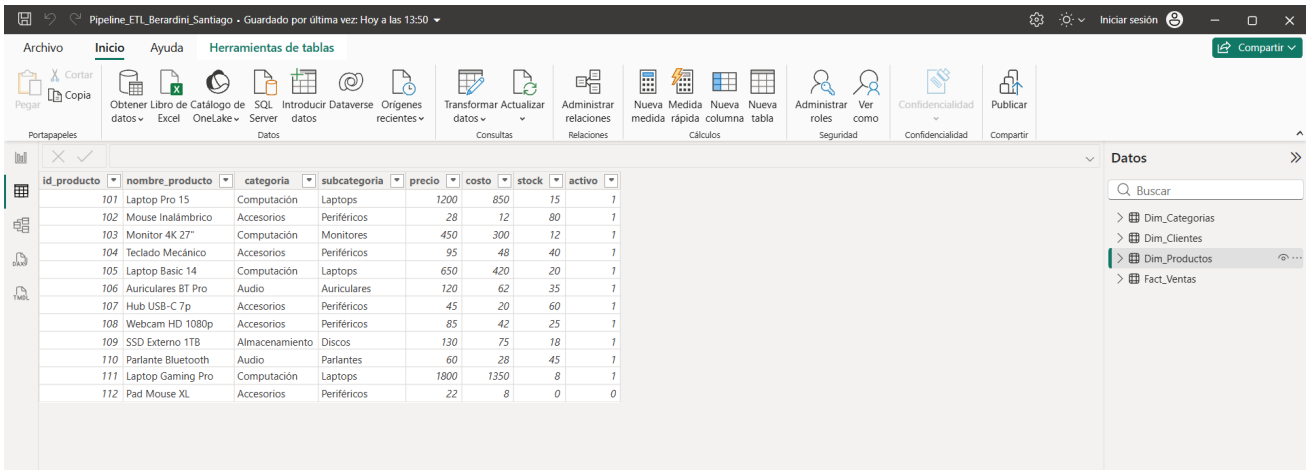
3. Vistas de datos: tablas de dimensión

Captura 3. Dim_Clientes: once clientes, sin duplicación de ID; se ven los reemplazos “Sin dato” en email y ciudad.



id_cliente	nombre_cliente	email	ciudad	pais	segmento	fecha_registro
1	María López	maria@mail.com	Buenos Aires	Argentina	Retail	martes, 15 de marzo de 2022
2	Carlos Ruiz	carlos@mail.com	Córdoba	Argentina	Corporativo	viernes, 20 de mayo de 2022
3	Ana Gómez	ana@mail.com	Santiago	Chile	Retail	domingo, 10 de julio de 2022
4	Pedro Sanz	pedro@mail.com	Montevideo	Uruguay	Corporativo	domingo, 8 de enero de 2023
5	Laura Torres	laura@mail.com	Rosario	Argentina	Retail	martes, 14 de febrero de 2023
6	Diego Mora	diego@mail.com	Lima	Perú	Mayorista	sábado, 22 de abril de 2023
7	Sofía Reyes	sofia@mail.com	Bogotá	Colombia	Retail	viernes, 30 de junio de 2023
8	Martín Cruz	martin@mail.com	Mendoza	Argentina	Corporativo	sábado, 5 de agosto de 2023
9	Valentina Paz	Sin dato	Asunción	Paraguay	Retail	lunes, 18 de septiembre de 2023
10	Lucía Vargas	lucia@mail.com	Buenos Aires	Argentina	Mayorista	sábado, 25 de noviembre de 2023
11	Roberto Díaz	roberto@mail.com	Sin dato	Argentina	Retail	miércoles, 10 de enero de 2024

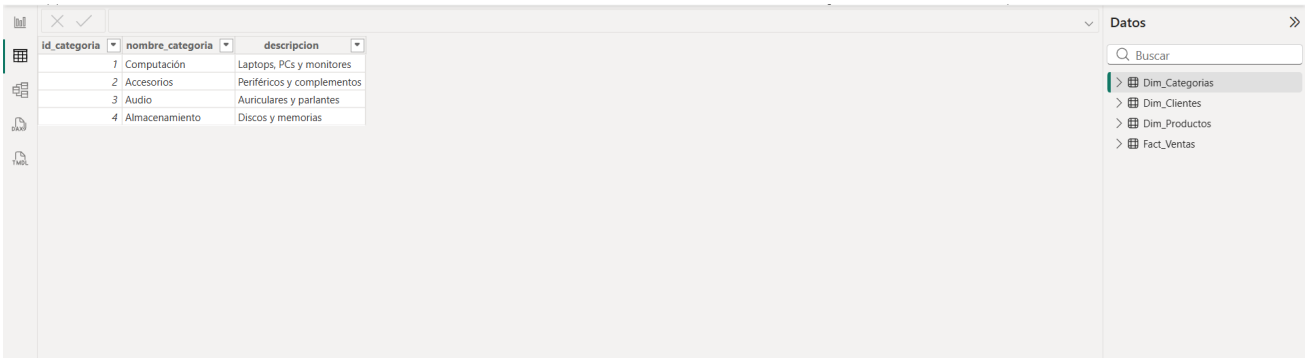
Captura 4. Dim_Productos: doce productos únicos, con precio 130 para el producto 109 y categoría Computación para el producto 111.



id_producto	nombre_producto	categoria	subcategoria	precio	costo	stock	activo
101	Laptop Pro 15	Computación	Laptops	1200	850	15	1
102	Mouse Inalámbrico	Accesorios	Periféricos	28	12	80	1
103	Monitor 4K 27"	Computación	Monitores	450	300	12	1
104	Teclado Mecánico	Accesorios	Periféricos	95	48	40	1
105	Laptop Basic 14	Computación	Laptops	650	420	20	1
106	Auriculares BT Pro	Audio	Auriculares	120	62	35	1
107	Hub USB-C 7p	Accesorios	Periféricos	45	20	60	1
108	Webcam HD 1080p	Accesorios	Periféricos	85	42	25	1
109	SSD Externo 1TB	Almacenamiento	Discos	130	75	18	1
110	Parlante Bluetooth	Audio	Parlantes	60	28	45	1
111	Laptop Gaming Pro	Computación	Laptops	1800	1350	8	1
112	Pad Mouse XL	Accesorios	Periféricos	22	8	0	0

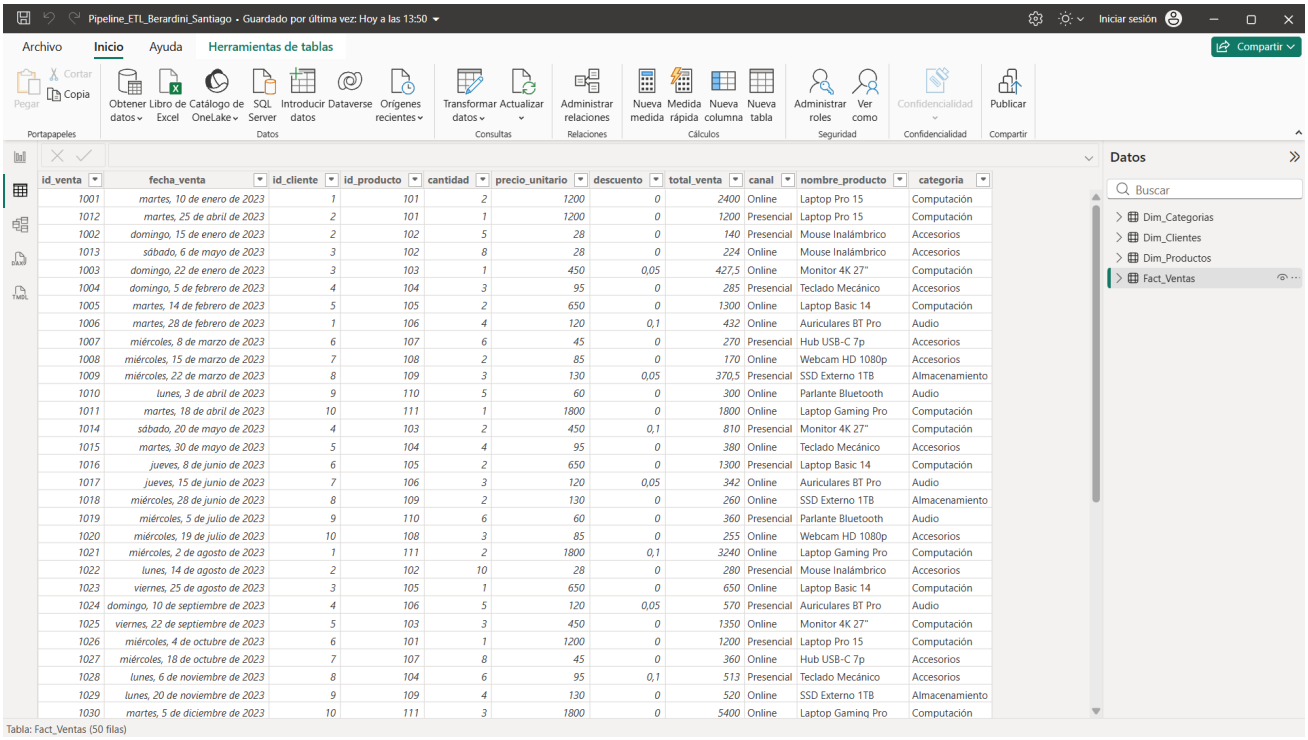
4. Vistas de datos: categorías y ventas

Captura 5. Dim_Categorias: cuatro registros válidos del catálogo de referencia.



id_categoria	nombre_categoria	descripcion
1	Computación	Laptops, PCs y monitores
2	Accesorios	Periféricos y complementos
3	Audio	Auriculares y parlantes
4	Almacenamiento	Discos y memorias

Captura 6. Fact_Ventas: 50 registros y las columnas de producto incorporadas al final de la tabla.



id_venta	fecha_venta	id_cliente	id_producto	cantidad	precio_unitario	descuento	total_venta	canal	nombre_producto	categoria
1001	martes, 10 de enero de 2023	1	101	2	1200	0	2400	Online	Laptop Pro 15	Computación
1012	martes, 25 de abril de 2023	2	101	1	1200	0	1200	Presencial	Laptop Pro 15	Computación
1002	domingo, 15 de enero de 2023	2	102	5	28	0	140	Presencial	Mouse Inalámbrico	Accesorios
1013	sábado, 6 de mayo de 2023	3	102	8	28	0	224	Online	Mouse Inalámbrico	Accesorios
1003	domingo, 22 de enero de 2023	3	103	1	450	0,05	427,5	Online	Monitor 4K 27"	Computación
1004	domingo, 5 de febrero de 2023	4	104	3	95	0	285	Presencial	Teclado Mecánico	Accesorios
1005	martes, 14 de febrero de 2023	5	105	2	650	0	1300	Online	Laptop Basic 14	Computación
1006	martes, 28 de febrero de 2023	1	106	4	120	0,1	432	Online	Auriculares BT Pro	Audio
1007	miércoles, 8 de marzo de 2023	6	107	6	45	0	270	Presencial	Hub USB-C 7p	Accesorios
1008	miércoles, 15 de marzo de 2023	7	108	2	85	0	170	Online	Webcam HD 1080p	Accesorios
1009	miércoles, 22 de marzo de 2023	8	109	3	130	0,05	370,5	Presencial	SSD Externo 1TB	Almacenamiento
1010	lunes, 3 de abril de 2023	9	110	5	60	0	300	Online	Parlante Bluetooth	Audio
1011	martes, 18 de abril de 2023	10	111	1	1800	0	1800	Online	Laptop Gaming Pro	Computación
1014	sábado, 20 de mayo de 2023	4	103	2	450	0,1	810	Presencial	Monitor 4K 27"	Computación
1015	martes, 30 de mayo de 2023	5	104	4	95	0	380	Online	Teclado Mecánico	Accesorios
1016	jueves, 8 de junio de 2023	6	105	2	650	0	1300	Presencial	Laptop Basic 14	Computación
1017	jueves, 15 de junio de 2023	7	106	3	120	0,05	342	Online	Auriculares BT Pro	Audio
1018	miércoles, 28 de junio de 2023	8	109	2	130	0	260	Online	SSD Externo 1TB	Almacenamiento
1019	miércoles, 5 de julio de 2023	9	110	6	60	0	360	Presencial	Parlante Bluetooth	Audio
1020	miércoles, 19 de julio de 2023	10	108	3	85	0	255	Online	Webcam HD 1080p	Accesorios
1021	miércoles, 2 de agosto de 2023	1	111	2	1800	0,1	3240	Online	Laptop Gaming Pro	Computación
1022	lunes, 14 de agosto de 2023	2	102	10	28	0	280	Presencial	Mouse Inalámbrico	Accesorios
1023	viernes, 25 de agosto de 2023	3	105	1	650	0	650	Online	Laptop Basic 14	Computación
1024	domingo, 10 de septiembre de 2023	4	106	5	120	0,05	570	Presencial	Auriculares BT Pro	Audio
1025	viernes, 22 de septiembre de 2023	5	103	3	450	0	1350	Online	Monitor 4K 27"	Computación
1026	miércoles, 4 de octubre de 2023	6	101	1	1200	0	1200	Presencial	Laptop Pro 15	Computación
1027	miércoles, 18 de octubre de 2023	7	107	8	45	0	360	Online	Hub USB-C 7p	Accesorios
1028	lunes, 6 de noviembre de 2023	8	104	6	95	0,1	513	Presencial	Teclado Mecánico	Accesorios
1029	lunes, 20 de noviembre de 2023	9	109	4	130	0	520	Online	SSD Externo 1TB	Almacenamiento
1030	martes, 5 de diciembre de 2023	10	111	3	1800	0	5400	Online	Laptop Gaming Pro	Computación

5. Trazabilidad de transformaciones

CONSULTA	PASO	QUÉ HACE / POR QUÉ
Todas	Origen / Navegación / Encabezados	Lee el libro Excel y establece los nombres de columna antes de transformar.
Todas	Filas_Validas	Excluye filas sin clave principal; impide que rangos vacíos se carguen como entidades o hechos.
Todas	Tipado	Establece tipos coherentes para claves, fechas, cantidades e importes; habilita cálculos y relaciones.
Dim_Clientes	Sin_Duplicados_Por_ID	Mantiene una fila por id_cliente para cumplir cardinalidad 1:N.
Dim_Clientes	Nulos_Con_Valor_Por_Defecto	Conserva clientes incompletos y clasifica atributos descriptivos faltantes.
Dim_Productos	Sin_Duplicados_Por_ID	Deja una sola fila por id_producto para impedir multiplicación de registros.
Dim_Productos	Precio_Imputado	Completa precio de producto 109 con valor histórico de venta, con supuesto documentado.
Dim_Productos	Categoria_Asignada	Completa categoría de producto 111 mediante subcategoría concordante.
Fact_Ventas	Merge_Productos	Une por id_producto con Left Outer; mantiene todas las ventas y aprovecha clave única de productos.
Fact_Ventas	Expandido	Añade nombre_producto y categoria sin copiar innecesariamente el resto de la dimensión.

6. Verificación final

Las evidencias muestran 11 registros en Dim_Clientes, 12 en Dim_Productos, 50 en Fact_Ventas y 4 en Dim_Categorias. La consulta de ventas posee once columnas y el resultado de la combinación contiene nombres y categorías de producto. No se aprecian errores de carga en las capturas aportadas.

Consideraciones técnicas

El filtro Filas_Validas se agregó luego de observar rangos vacíos importados. En un sistema real conviene completar la imputación del precio con una regla de trazabilidad y confirmar la cifra con el área comercial antes de usarla para decisiones financieras.

7. Lenguaje M: consultas documentadas

Se muestran las cuatro consultas con nombres de pasos y comentarios técnicos. Se incorpora Filas_Validas antes de Tipado para reflejar la corrección aplicada en Power BI Desktop.

Dim_Clientes

```
let
    // La ruta queda guardada en el .pbix: si se mueve el Excel hay que actualizarla en Configuración de
    origen de datos
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "clientes", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_cliente] <> null),

    // Se tipa ANTES de deduplicar: si id_cliente quedara como texto, "1" y 1 podrían tratarse como
    claves distintas
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_cliente", Int64.Type},
        {"nombre_cliente", type text},
        {"email", type text},
        {"ciudad", type text},
        {"pais", type text},
        {"segmento", type text},
        {"fecha_registro", type date}
    }),

    // Se deduplica solo por id_cliente: la PK de la dimensión debe ser única para que la relación 1:N
    del Módulo 8 funcione.
    // Deduplicar por todas las columnas dejaría pasar un duplicado que difiera en un solo campo
    Sin_Duplicados_Por_ID = Table.Distinct(Tipado, {"id_cliente"}),

    // No se eliminan los clientes con nulos: el cliente 9 tiene 5 ventas y borrarlo dejaría hechos
    huérfanos;
    // el cliente 11 es un registro válido del CRM aunque todavía no compró. email y ciudad son atributos
    descriptivos, no claves ni medidas
    Nulos_Con_Valor_Por_Defecto = Table.ReplaceValue(Sin_Duplicados_Por_ID, null, "Sin dato",
    Replacer.ReplaceValue, {"email", "ciudad"})
in
    Nulos_Con_Valor_Por_Defecto
```

Dim_Productos

```
let
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "productos", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_producto] <> null),

    // Los importes se tipan como decimal para que SUM y AVERAGE funcionen en DAX (Módulo 8).
    // stock y activo son enteros: activo es un indicador 0/1
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_producto", Int64.Type},
        {"nombre_producto", type text},
        {"categoria", type text},
        {"subcategoria", type text},
        {"precio", type number},
        {"costo", type number},
        {"stock", Int64.Type},
        {"activo", Int64.Type}
    }),

    // El id_producto 103 viene repetido: se conserva una sola fila por PK para no duplicar ingresos al
    relacionar con Fact_Ventas
    Sin_Duplicados_Por_ID = Table.Distinct(Tipado, {"id_producto"}),

    // El producto 109 no tiene precio, pero sus 5 ventas registran precio_unitario = 130 en todos los
    casos.
    // Se imputa ese valor observado: el promedio del catálogo (414,09) triplicaría el precio real y un 0
    distorsionaría el margen.
    // No se elimina la fila porque el producto tiene ventas y el catálogo debe quedar en 12 productos
    Precio_Imputado = Table.ReplaceValue(Sin_Duplicados_Por_ID, null, 130, Replacer.ReplaceValue,
    {"precio"}),

    // El producto 111 es de subcategoria "Laptops" y las otras dos laptops (101 y 105) son "Computación".
    // Se asigna esa categoría y no "Sin Categoría" porque sus 5 ventas (15.840 facturados) quedarían
    fuera del análisis por categoría.
    // El reemplazo global es seguro porque hay un único nulo en la columna; con más nulos habría que
    condicionarlo por subcategoria
    Categoria_Asignada = Table.ReplaceValue(Precio_Imputado, null, "Computación", Replacer.ReplaceValue,
    {"categoria"})
in
    Categoria_Asignada
```

Dim_Categorias

```
let
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "categorias", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_categoria] <> null),

    // La tabla viene limpia: solo se tipa para que id_categoria sea una clave entera consistente con el
    resto del modelo
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_categoria", Int64.Type},
        {"nombre_categoria", type text},
        {"descripcion", type text}
    })
in
    Tipado
```

Fact_Ventas

```
let
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "ventas", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_venta] <> null),

    // fecha_venta como Date es condición para la tabla calendario y las líneas de tiempo de los Módulos
    7 y 8.
    // descuento se tipa como decimal porque es una proporción (0,05 = 5%)
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_venta", Int64.Type},
        {"fecha_venta", type date},
        {"id_cliente", Int64.Type},
        {"id_producto", Int64.Type},
        {"cantidad", Int64.Type},
        {"precio_unitario", type number},
        {"descuento", type number},
        {"total_venta", type number},
        {"canal", type text}
    }),

    // Left Outer: la tabla de hechos manda. Un Inner descartaría ventas cuyo producto no esté en la
    dimensión y falsearía el total.
    // La clave tiene el mismo tipo (Int64) en ambas consultas; con tipos distintos el Merge no
    encontraría coincidencias
    Merge_Productos = Table.NestedJoin(Tipado, {"id_producto"}, Dim_Productos, {"id_producto"},
    "Dim_Productos", JoinKind.LeftOuter),

    // Se expanden solo dos columnas: traer toda la dimensión duplicaría atributos y engordaría el modelo.
    // Dim_Productos ya llega sin nulos en categoria, por eso Fact_Ventas hereda la categoría completa
    Expandido = Table.ExpandTableColumn(Merge_Productos, "Dim_Productos", {"nombre_producto",
    "categoria"}, {"nombre_producto", "categoria"})
in
    Expandido
```

8. Archivo Power BI y publicación

Archivo complementario: Pipeline_ETL_Berardini_Santiago.pbix. La versión actualizada fue entregada para acompañar este documento; se recomienda publicarla en el mismo directorio de GitHub que el PDF.

Repositorio del proyecto

https://github.com/SantiagoBerardini/retailpro-data-analyst

Importante para la entrega

Este enlace corresponde al repositorio existente, no constituye por sí solo una URL verificada al archivo .pbix. Para cumplir literalmente el criterio de “link al .pbix” se debe subir el archivo y sustituir o complementar este apartado con la dirección directa al .pbix publicado. No se incluye un vínculo directo inventado.

Archivos recomendados en GitHub

- Pipeline_ETL_Berardini_Santiago.pdf
- Pipeline_ETL_Berardini_Santiago.pbix
- Pipeline_ETL_Dataset.xlsx (fuente utilizada, si la licencia del curso permite compartirla)

Conclusión

El pipeline implementa limpieza, normalización de tipos, deduplicación y combinación de tablas. La preparación documentada permite continuar con relaciones, calendario y medidas de análisis en Power BI.