PRE-ENTREGA 6 · POWER QUERY + M

Pipeline ETL de TechStore

De datos crudos a un modelo confiable para Power BI

PROYECTO	ENTREGA
RetailPro / TechStore	Checkpoint: Pipeline ETL con Power Query y lenguaje M
Alumno	Santiago Berardini
Fuente	Pipeline_ETL_Dataset.xlsx
Archivo Power BI	Pipeline_ETL_Berardini_Santiago.pbix

Objetivo

Preparar las tablas de clientes, productos, ventas y categorías mediante un proceso de extracción, transformación y carga (ETL). El resultado conserva los registros de negocio válidos, resuelve problemas de calidad y enriquece la tabla de ventas con los atributos de producto para el análisis de los módulos posteriores.

Resultado comprobado

CONSULTA	ORIGEN	FINAL	VALIDACIÓN
Dim_Clientes	12	11	ID único; nulos descriptivos resueltos
Dim_Productos	13	12	ID único; precio y categoría completados
Fact_Ventas	50	50	Merge por id_producto; 11 columnas
Dim_Categorias	4	4	Catálogo de referencia sin cambios

Nota de alcance: los conteos y la vista final se documentan con capturas reales de Power BI Desktop. El archivo .pbix se entrega como material complementario junto a este PDF.

1. Conexión, perfilado y limpieza

La fuente corresponde al libro Excel del curso, no a la base SQL utilizada en los módulos anteriores. Se trabajó en el Editor de Power Query y se cargaron cuatro consultas con la nomenclatura profesional Dim_ / Fact_.

Calidad de datos: decisiones aplicadas

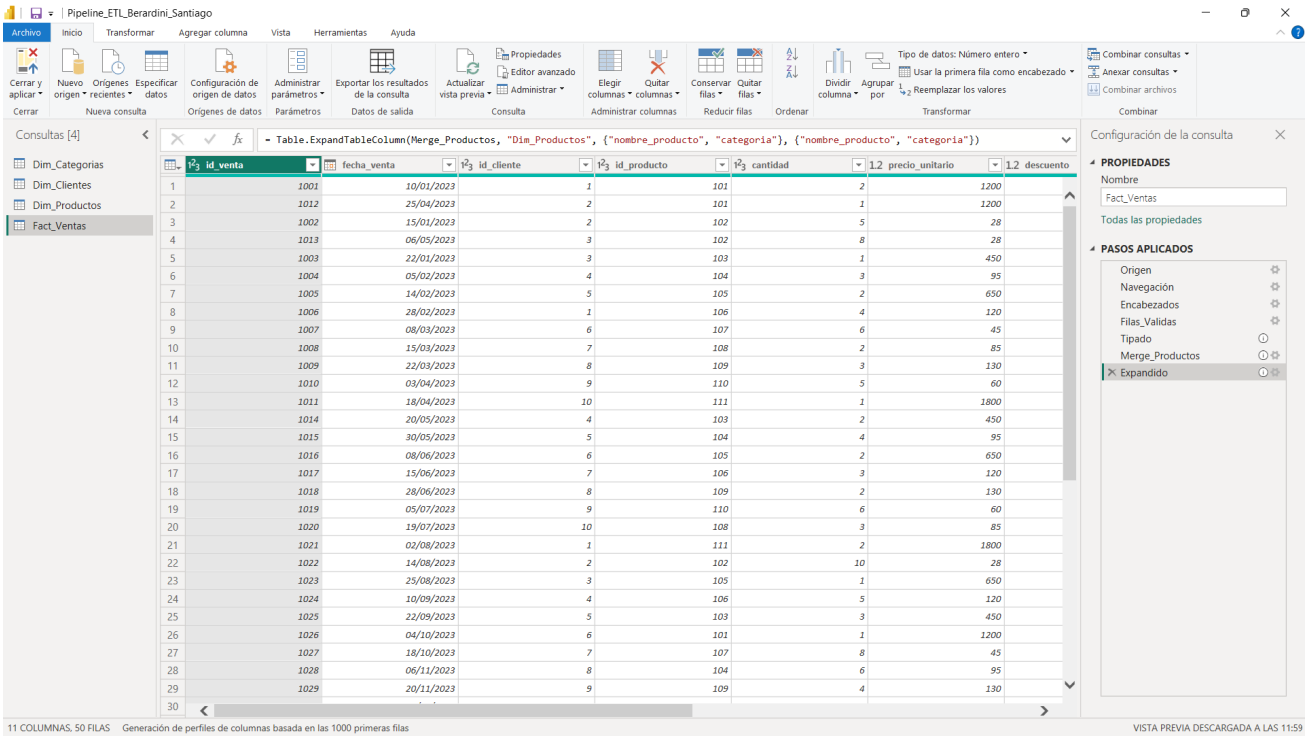
CONSULTA	PROBLEMA	TRANSFORMACIÓN Y CRITERIO
Dim_Clientes	1 ID duplicado	Quitar duplicados por id_cliente para mantener una clave primaria única.
Dim_Clientes	Email nulo, cliente 9	Sustituir por “Sin dato”. Conservar el cliente evita perder la correspondencia con ventas.
Dim_Clientes	Ciudad nula, cliente 11	Sustituir por “Sin dato”. Es un atributo descriptivo, no una clave.
Dim_Productos	ID 103 repetido	Quitar duplicados por id_producto para evitar duplicación de productos al combinar.
Dim_Productos	Precio nulo, producto 109	Imputar 130, valor observado en sus ventas. Requiere validación comercial si fuera una fuente de producción.
Dim_Productos	Categoría nula, producto 111	Asignar “Computación”, coherente con su subcategoría Laptops y productos comparables.
Todas	Filas sin identificador	Filtrar registros con ID nulo antes de tipar y reemplazar valores; evita que filas vacías se conviertan en registros ficticios.

Tipos de datos

TABLA	ASIGNACIÓN
Dim_Clientes	id_cliente: entero; fecha_registro: fecha; nombre_cliente, email, ciudad, pais y segmento: texto.
Dim_Productos	id_producto, stock y activo: entero; precio y costo: decimal; nombre_producto, categoria y subcategoria: texto.
Fact_Ventas	id_venta, id_cliente, id_producto y cantidad: entero; fecha_venta: fecha; precio_unitario, descuento y total_venta: decimal; canal: texto.
Dim_Categorias	id_categoria: entero; nombre_categoria y descripcion: texto.

2. Evidencias de Power Query

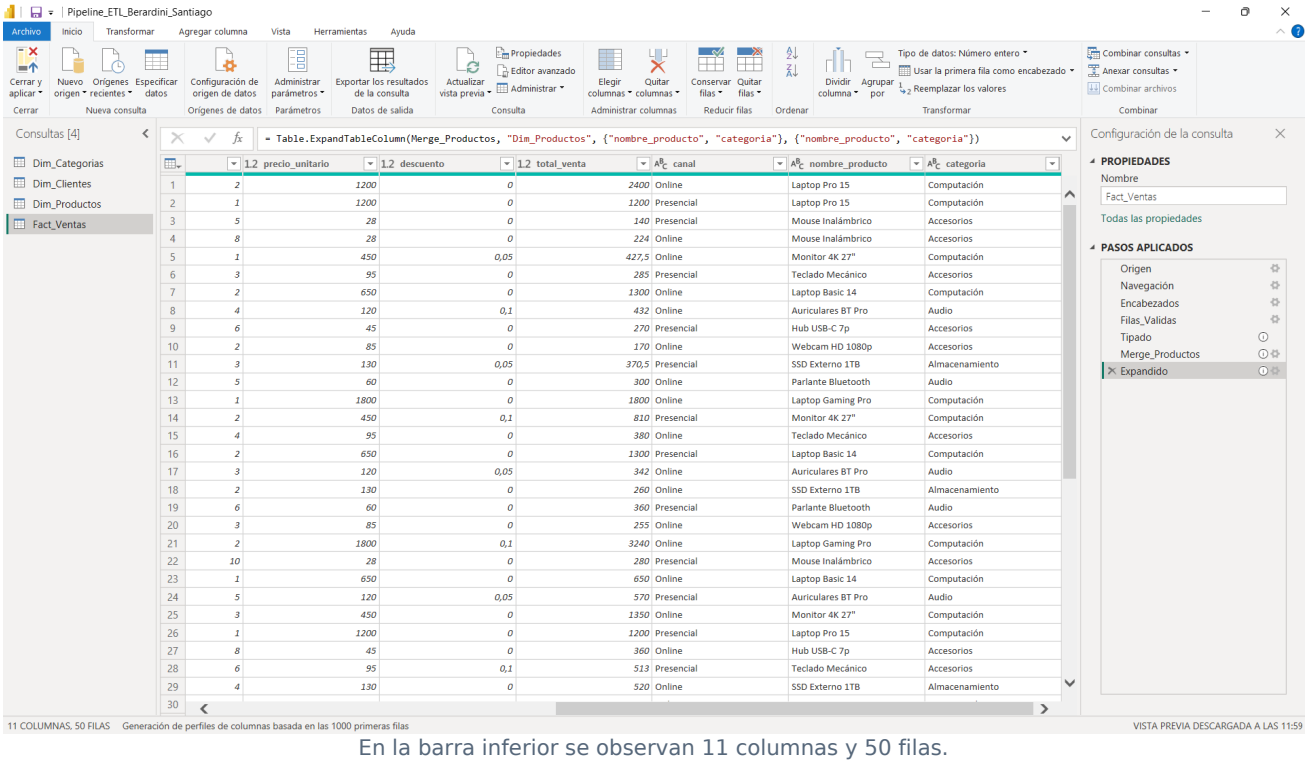
Captura 1. Panel de consultas y pasos aplicados de Fact_Ventas. Se distinguen las cuatro consultas, el filtro Filas_Validas, la combinación Merge_Productos y la expansión final.



Fuente: captura real del Editor de Power Query, posterior a la corrección de filas vacías.

Captura 2. Verificación del resultado del Merge

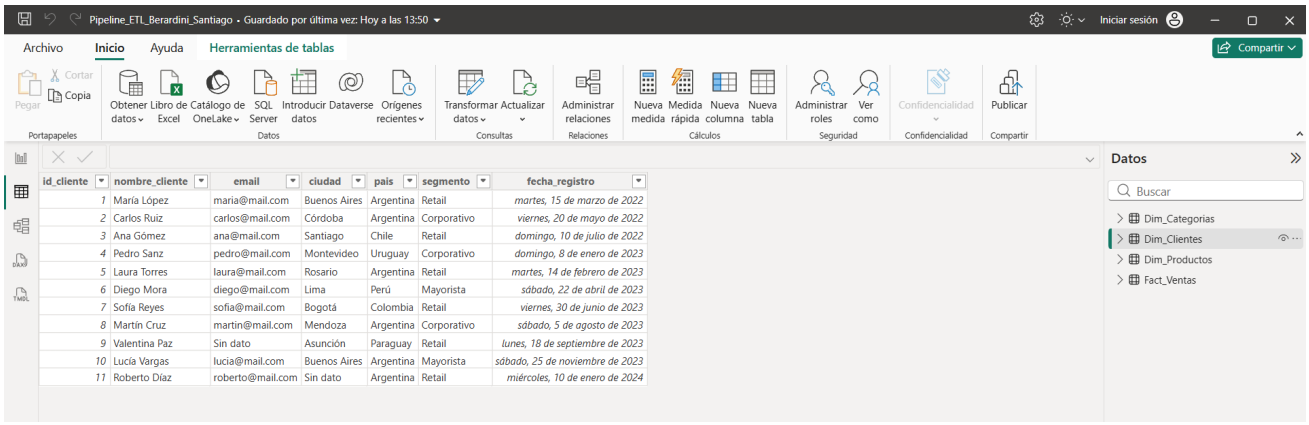
La consulta Fact_Ventas conserva las 50 operaciones y muestra las columnas nombre_producto y categoria incorporadas por la combinación con Dim_Productos.



En la barra inferior se observan 11 columnas y 50 filas.

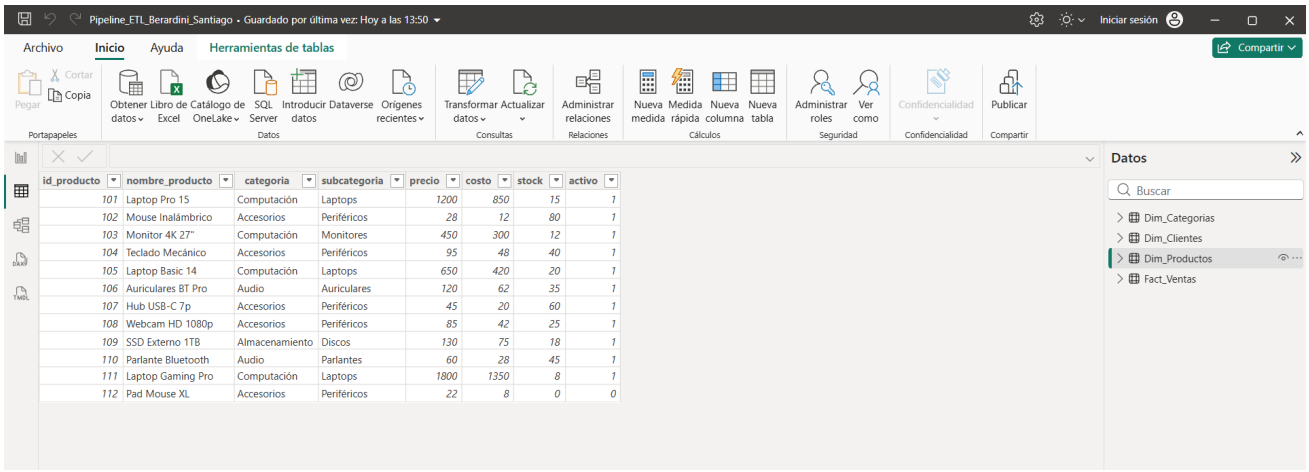
3. Vistas de datos: tablas de dimensión

Captura 3. Dim_Clientes: once clientes, sin duplicación de ID; se ven los reemplazos “Sin dato” en email y ciudad.



id_cliente	nombre_cliente	email	ciudad	pais	segmento	fecha_registro
1	María López	maria@mail.com	Buenos Aires	Argentina	Retail	martes, 15 de marzo de 2022
2	Carlos Ruiz	carlos@mail.com	Córdoba	Argentina	Corporativo	viernes, 20 de mayo de 2022
3	Ana Gómez	ana@mail.com	Santiago	Chile	Retail	domingo, 10 de julio de 2022
4	Pedro Sanz	pedro@mail.com	Montevideo	Uruguay	Corporativo	domingo, 8 de enero de 2023
5	Laura Torres	laura@mail.com	Rosario	Argentina	Retail	martes, 14 de febrero de 2023
6	Diego Mora	diego@mail.com	Lima	Perú	Mayorista	sábado, 22 de abril de 2023
7	Sofía Reyes	sofia@mail.com	Bogotá	Colombia	Retail	viernes, 30 de junio de 2023
8	Martín Cruz	martin@mail.com	Mendoza	Argentina	Corporativo	sábado, 5 de agosto de 2023
9	Valentina Paz	Sin dato	Asunción	Paraguay	Retail	lunes, 18 de septiembre de 2023
10	Lucía Vargas	lucia@mail.com	Buenos Aires	Argentina	Mayorista	sábado, 25 de noviembre de 2023
11	Roberto Díaz	roberto@mail.com	Sin dato	Argentina	Retail	miércoles, 10 de enero de 2024

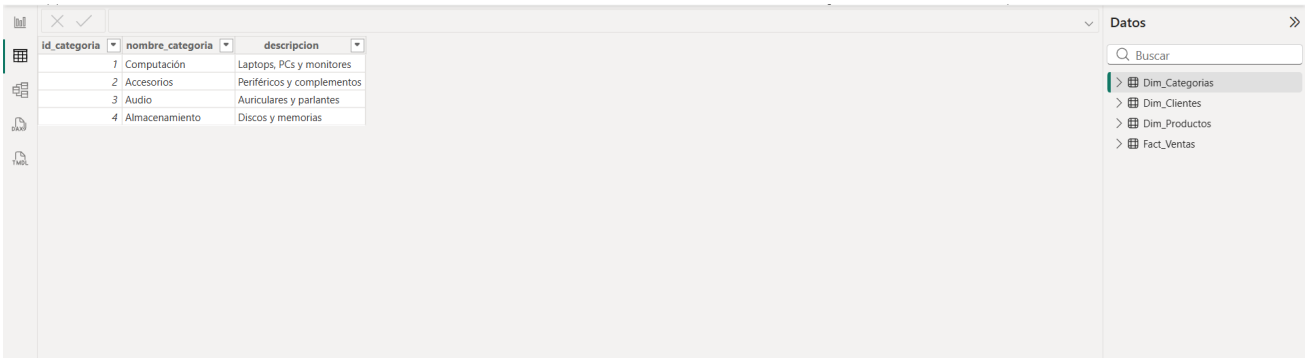
Captura 4. Dim_Productos: doce productos únicos, con precio 130 para el producto 109 y categoría Computación para el producto 111.



id_producto	nombre_producto	categoria	subcategoria	precio	costo	stock	activo
101	Laptop Pro 15	Computación	Laptops	1200	850	15	1
102	Mouse Inalámbrico	Accesorios	Periféricos	28	12	80	1
103	Monitor 4K 27"	Computación	Monitores	450	300	12	1
104	Teclado Mecánico	Accesorios	Periféricos	95	48	40	1
105	Laptop Basic 14	Computación	Laptops	650	420	20	1
106	Auriculares BT Pro	Audio	Auriculares	120	62	35	1
107	Hub USB-C 7p	Accesorios	Periféricos	45	20	60	1
108	Webcam HD 1080p	Accesorios	Periféricos	85	42	25	1
109	SSD Externo 1TB	Almacenamiento	Discos	130	75	18	1
110	Parlante Bluetooth	Audio	Parlantes	60	28	45	1
111	Laptop Gaming Pro	Computación	Laptops	1800	1350	8	1
112	Pad Mouse XL	Accesorios	Periféricos	22	8	0	0

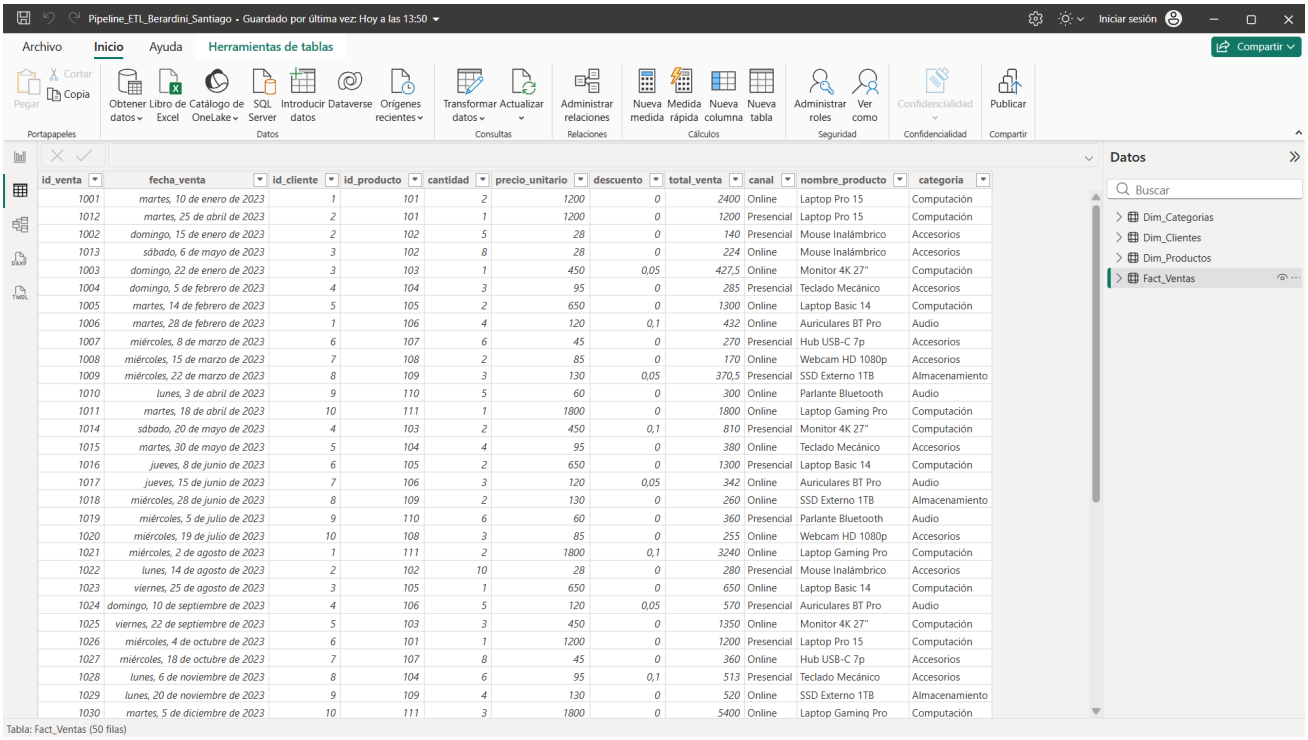
4. Vistas de datos: categorías y ventas

Captura 5. Dim_Categorias: cuatro registros válidos del catálogo de referencia.



id_categoria	nombre_categoria	descripcion
1	Computación	Laptops, PCs y monitores
2	Accesorios	Periféricos y complementos
3	Audio	Auriculares y parlantes
4	Almacenamiento	Discos y memorias

Captura 6. Fact_Ventas: 50 registros y las columnas de producto incorporadas al final de la tabla.



id_venta	fecha_venta	id_cliente	id_producto	cantidad	precio_unitario	descuento	total_venta	canal	nombre_producto	categoria
1001	martes, 10 de enero de 2023	1	101	2	1200	0	2400	Online	Laptop Pro 15	Computación
1012	martes, 25 de abril de 2023	2	101	1	1200	0	1200	Presencial	Laptop Pro 15	Computación
1002	domingo, 15 de enero de 2023	2	102	5	28	0	140	Presencial	Mouse Inalámbrico	Accesorios
1013	sábado, 6 de mayo de 2023	3	102	8	28	0	224	Online	Mouse Inalámbrico	Accesorios
1003	domingo, 22 de enero de 2023	3	103	1	450	0,05	427,5	Online	Monitor 4K 27"	Computación
1004	domingo, 5 de febrero de 2023	4	104	3	95	0	285	Presencial	Teclado Mecánico	Accesorios
1005	martes, 14 de febrero de 2023	5	105	2	650	0	1300	Online	Laptop Basic 14	Computación
1006	martes, 28 de febrero de 2023	1	106	4	120	0,1	432	Online	Auriculares BT Pro	Audio
1007	miércoles, 8 de marzo de 2023	6	107	6	45	0	270	Presencial	Hub USB-C 7p	Accesorios
1008	miércoles, 15 de marzo de 2023	7	108	2	85	0	170	Online	Webcam HD 1080p	Accesorios
1009	miércoles, 22 de marzo de 2023	8	109	3	130	0,05	370,5	Presencial	SSD Externo 1TB	Almacenamiento
1010	lunes, 3 de abril de 2023	9	110	5	60	0	300	Online	Parlante Bluetooth	Audio
1011	martes, 18 de abril de 2023	10	111	1	1800	0	1800	Online	Laptop Gaming Pro	Computación
1014	sábado, 20 de mayo de 2023	4	103	2	450	0,1	810	Presencial	Monitor 4K 27"	Computación
1015	martes, 30 de mayo de 2023	5	104	4	95	0	380	Online	Teclado Mecánico	Accesorios
1016	jueves, 8 de junio de 2023	6	105	2	650	0	1300	Presencial	Laptop Basic 14	Computación
1017	jueves, 15 de junio de 2023	7	106	3	120	0,05	342	Online	Auriculares BT Pro	Audio
1018	miércoles, 28 de junio de 2023	8	109	2	130	0	260	Online	SSD Externo 1TB	Almacenamiento
1019	miércoles, 5 de julio de 2023	9	110	6	60	0	360	Presencial	Parlante Bluetooth	Audio
1020	miércoles, 19 de julio de 2023	10	108	3	85	0	255	Online	Webcam HD 1080p	Accesorios
1021	miércoles, 2 de agosto de 2023	1	111	2	1800	0,1	3240	Online	Laptop Gaming Pro	Computación
1022	lunes, 14 de agosto de 2023	2	102	10	28	0	280	Presencial	Mouse Inalámbrico	Accesorios
1023	viernes, 25 de agosto de 2023	3	105	1	650	0	650	Online	Laptop Basic 14	Computación
1024	domingo, 10 de septiembre de 2023	4	106	5	120	0,05	570	Presencial	Auriculares BT Pro	Audio
1025	viernes, 22 de septiembre de 2023	5	103	3	450	0	1350	Online	Monitor 4K 27"	Computación
1026	miércoles, 4 de octubre de 2023	6	101	1	1200	0	1200	Presencial	Laptop Pro 15	Computación
1027	miércoles, 18 de octubre de 2023	7	107	8	45	0	360	Online	Hub USB-C 7p	Accesorios
1028	lunes, 6 de noviembre de 2023	8	104	6	95	0,1	513	Presencial	Teclado Mecánico	Accesorios
1029	lunes, 20 de noviembre de 2023	9	109	4	130	0	520	Online	SSD Externo 1TB	Almacenamiento
1030	martes, 5 de diciembre de 2023	10	111	3	1800	0	5400	Online	Laptop Gaming Pro	Computación

5. Trazabilidad de transformaciones

CONSULTA	PASO	QUÉ HACE / POR QUÉ
Todas	Origen / Navegación / Encabezados	Lee el libro Excel y establece los nombres de columna antes de transformar.
Todas	Filas_Validas	Excluye filas sin clave principal; impide que rangos vacíos se carguen como entidades o hechos.
Todas	Tipado	Establece tipos coherentes para claves, fechas, cantidades e importes; habilita cálculos y relaciones.
Dim_Clientes	Sin_Duplicados_Por_ID	Mantiene una fila por id_cliente para cumplir cardinalidad 1:N.
Dim_Clientes	Nulos_Con_Valor_Por_Defecto	Conserva clientes incompletos y clasifica atributos descriptivos faltantes.
Dim_Productos	Sin_Duplicados_Por_ID	Deja una sola fila por id_producto para impedir multiplicación de registros.
Dim_Productos	Precio_Imputado	Completa precio de producto 109 con valor histórico de venta, con supuesto documentado.
Dim_Productos	Categoria_Asignada	Completa categoría de producto 111 mediante subcategoría concordante.
Fact_Ventas	Merge_Productos	Une por id_producto con Left Outer; mantiene todas las ventas y aprovecha clave única de productos.
Fact_Ventas	Expandido	Añade nombre_producto y categoria sin copiar innecesariamente el resto de la dimensión.

6. Verificación final

Las evidencias muestran 11 registros en Dim_Clientes, 12 en Dim_Productos, 50 en Fact_Ventas y 4 en Dim_Categorias. La consulta de ventas posee once columnas y el resultado de la combinación contiene nombres y categorías de producto. No se aprecian errores de carga en las capturas aportadas.

Consideraciones técnicas

El filtro Filas_Validas se agregó luego de observar rangos vacíos importados. En un sistema real conviene completar la imputación del precio con una regla de trazabilidad y confirmar la cifra con el área comercial antes de usarla para decisiones financieras.

7. Lenguaje M: consultas documentadas

Se muestran las cuatro consultas con nombres de pasos y comentarios técnicos. Se incorpora Filas_Validas antes de Tipado para reflejar la corrección aplicada en Power BI Desktop.

Dim_Clientes

```
let
    // La ruta queda guardada en el .pbix: si se mueve el Excel hay que actualizarla en Configuración de
    origen de datos
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "clientes", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_cliente] <> null),

    // Se tipa ANTES de deduplicar: si id_cliente quedara como texto, "1" y 1 podrían tratarse como
    claves distintas
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_cliente", Int64.Type},
        {"nombre_cliente", type text},
        {"email", type text},
        {"ciudad", type text},
        {"pais", type text},
        {"segmento", type text},
        {"fecha_registro", type date}
    }),

    // Se deduplica solo por id_cliente: la PK de la dimensión debe ser única para que la relación 1:N
    del Módulo 8 funcione.
    // Deduplicar por todas las columnas dejaría pasar un duplicado que difiera en un solo campo
    Sin_Duplicados_Por_ID = Table.Distinct(Tipado, {"id_cliente"}),

    // No se eliminan los clientes con nulos: el cliente 9 tiene 5 ventas y borrarlo dejaría hechos
    huérfanos;
    // el cliente 11 es un registro válido del CRM aunque todavía no compró. email y ciudad son atributos
    descriptivos, no claves ni medidas
    Nulos_Con_Valor_Por_Defecto = Table.ReplaceValue(Sin_Duplicados_Por_ID, null, "Sin dato",
    Replacer.ReplaceValue, {"email", "ciudad"})
in
    Nulos_Con_Valor_Por_Defecto
```

Dim_Productos

```
let
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "productos", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_producto] <> null),

    // Los importes se tipan como decimal para que SUM y AVERAGE funcionen en DAX (Módulo 8).
    // stock y activo son enteros: activo es un indicador 0/1
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_producto", Int64.Type},
        {"nombre_producto", type text},
        {"categoria", type text},
        {"subcategoria", type text},
        {"precio", type number},
        {"costo", type number},
        {"stock", Int64.Type},
        {"activo", Int64.Type}
    }),

    // El id_producto 103 viene repetido: se conserva una sola fila por PK para no duplicar ingresos al
    relacionar con Fact_Ventas
    Sin_Duplicados_Por_ID = Table.Distinct(Tipado, {"id_producto"}),

    // El producto 109 no tiene precio, pero sus 5 ventas registran precio_unitario = 130 en todos los
    casos.
    // Se imputa ese valor observado: el promedio del catálogo (414,09) triplicaría el precio real y un 0
    distorsionaría el margen.
    // No se elimina la fila porque el producto tiene ventas y el catálogo debe quedar en 12 productos
    Precio_Imputado = Table.ReplaceValue(Sin_Duplicados_Por_ID, null, 130, Replacer.ReplaceValue,
    {"precio"}),

    // El producto 111 es de subcategoria "Laptops" y las otras dos laptops (101 y 105) son "Computación".
    // Se asigna esa categoría y no "Sin Categoría" porque sus 5 ventas (15.840 facturados) quedarían
    fuera del análisis por categoría.
    // El reemplazo global es seguro porque hay un único nulo en la columna; con más nulos habría que
    condicionarlo por subcategoria
    Categoria_Asignada = Table.ReplaceValue(Precio_Imputado, null, "Computación", Replacer.ReplaceValue,
    {"categoria"})
in
    Categoria_Asignada
```

Dim_Categorias

```
let
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "categorias", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_categoria] <> null),

    // La tabla viene limpia: solo se tipa para que id_categoria sea una clave entera consistente con el
    resto del modelo
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_categoria", Int64.Type},
        {"nombre_categoria", type text},
        {"descripcion", type text}
    })
in
    Tipado
```

Fact_Ventas

```
let
    Origen = Excel.Workbook(File.Contents("C:\Datos\Pipeline_ETL_Dataset.xlsx"), null, true),
    Hoja = Origen{[Item = "ventas", Kind = "Sheet"]}[Data],
    Encabezados = Table.PromoteHeaders(Hoja, [PromoteAllScalars = true]),
    // Se excluyen filas sin clave antes de imputar atributos, para no crear registros ficticios.
    Filas_Validas = Table.SelectRows(Encabezados, each [id_venta] <> null),

    // fecha_venta como Date es condición para la tabla calendario y las líneas de tiempo de los Módulos
    7 y 8.
    // descuento se tipa como decimal porque es una proporción (0,05 = 5%)
    Tipado = Table.TransformColumnTypes(Filas_Validas, {
        {"id_venta", Int64.Type},
        {"fecha_venta", type date},
        {"id_cliente", Int64.Type},
        {"id_producto", Int64.Type},
        {"cantidad", Int64.Type},
        {"precio_unitario", type number},
        {"descuento", type number},
        {"total_venta", type number},
        {"canal", type text}
    }),

    // Left Outer: la tabla de hechos manda. Un Inner descartaría ventas cuyo producto no esté en la
    dimensión y falsearía el total.
    // La clave tiene el mismo tipo (Int64) en ambas consultas; con tipos distintos el Merge no
    encontraría coincidencias
    Merge_Productos = Table.NestedJoin(Tipado, {"id_producto"}, Dim_Productos, {"id_producto"},
    "Dim_Productos", JoinKind.LeftOuter),

    // Se expanden solo dos columnas: traer toda la dimensión duplicaría atributos y engordaría el modelo.
    // Dim_Productos ya llega sin nulos en categoria, por eso Fact_Ventas hereda la categoría completa
    Expandido = Table.ExpandTableColumn(Merge_Productos, "Dim_Productos", {"nombre_producto",
    "categoria"}, {"nombre_producto", "categoria"})
in
    Expandido
```

8. Archivo Power BI y publicacion

El proyecto Power BI y su evidencia documental estan publicados en el repositorio RetailPro, en la carpeta correspondiente al modulo 6.

Archivo PBIX - enlace directo

Pipeline_ETL_Berardini_Santiago.pbix
Abrir el archivo en GitHub (enlace de lectura):

github.com/SantiagoBerardini/retailpro-data-analyst/blob/main/retailpro-data-analyst/modulo-6-pipeline-etl/Pipeline_ETL_Berardini_Santiago.pbix

Carpeta del modulo 6

Incluye el archivo .pbix, el PDF de evidencias y un README del modulo.

Abrir carpeta en GitHub

Conclusion

El pipeline incorpora limpieza, tipado, deduplicacion, filtrado de filas sin ID y enriquecimiento de ventas mediante un Merge con Dim_Productos. Las capturas documentan los conteos finales: 11 clientes, 12 productos, 50 ventas y 4 categorias. El archivo PBIX se conserva para los siguientes modulos.